



Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador

Avance 1.

Análisis Exploratorio de Datos (EDA)

Alumnos:

Nombre	Matrícula
Isaura Yutsil Flores Escamilla	A01796552
Paola Alejandra León Guarneros	A01796230
Dylan Ulises Quiroz Hernández	A01796578

4 de Octubre de 2026

Índice

1. Introducción y descripción del conjunto de datos.....	3
2. Valores faltantes y patrones de ausencia.....	4
2.1 Archivos faltantes.....	4
2.2 Valores faltantes dentro de la señal.....	4
2.3 Patrón de ausencia: muestras sin etiquetar.....	4
3. Estadísticas resumidas.....	5
3.1 Participantes.....	5
3.2 Registros sEMG.....	6
4. Valores faltantes y calidad temporal.....	7
5. Valores atípicos.....	7
5.1 Atípicos en la amplitud sEMG.....	7
5.2 Valores atípicos en las anotaciones.....	9
5.3 Valores por encima de 100% MVC.....	9
6. Tendencias temporales.....	9
6.1 Estructura temporal de cada ensayo.....	9
6.2 Dinámica de la señal dentro del ensayo.....	9
6.3 Sincronización entre modalidades.....	10
7. Desequilibrio de las acciones etiquetadas.....	11
8. Preprocesamiento.....	12
8.1 Trazabilidad.....	12
8.2 Transformación y homogeneización de la señal.....	12
8.3 Segmentación y selección de variables.....	13
8.4 Particionado y control del desequilibrio.....	13
9. Conclusiones.....	13
9.1 Calidad.....	13
9.2 Capacidad predictiva.....	14
9.3 Limitaciones.....	14
9.4 Recomendaciones de modelado.....	15
10. Referencias.....	16

1. Introducción y descripción del conjunto de datos

El presente trabajo presenta el análisis exploratorio (EDA) del conjunto de datos de Bassani, Filippeschi y Avizzano (IEEE Sensors Journal, 2021), que contiene registros de electromiografía de superficie (sEMG) y captura de movimiento de cuerpo completo (Xsens MVN) sobre 14 sujetos, los cuales fueron sometidos a diversos ensayos de tareas de manejo manual con la finalidad de capturar las señales musculares. El objetivo del presente documento es describir la estructura y calidad de los datos, así como la extracción de conclusiones que orienten el modelo de reconocimiento de actividad humana (HAR).

El conjunto se compone de cinco elementos, todos vinculados por el nombre del archivo, que codifica sujeto, tarea, lado, carga y condición, como se muestra en la siguiente tabla:

Carpeta	Contenido	Formato
Data/Subj_XX/	sEMG, 8 canales, con un CSV por cada ensayo	CSV
Labels/Subj_XX/	Segmento de actividad, o ventana MVC	CSV
mvnx_files/Subj_XX/	Captura de movimiento de cuerpo entero Xsens, un archivo por ensayo	MVNX (XML)
Subs_info	Antropometría de los 14 participantes	XLSX
m_files/	scripts de MATLAB utilizados por los autores para filtrar y normalizar sEMG	.m

Tabla 1. Archivos del dataset en Zenodo (Bassani et al., 2021b).

Cada subcarpeta contiene los ensayos realizados por sujeto, y cada sujeto realiza 37 ensayos:

- 16 isocinéticos (Isokin; brazo derecho/izquierdo (R/I) x cargas (2 y 4 kg) x estático/40/50/80 bpm).
- 9 MMH bimanual (MMH_Bim; 2, 8, 12 kg x 3 repeticiones; un archivo sEMG por brazo).
- 12 MMH a una mano (MMH_One; L/R x 2 y 4 kg x 3 repeticiones).

Para realizar las mediciones, se colocaron 8 canales a los sujetos en puntos estratégicos del cuerpo (muñecas, codos, rodillas), por lo que los archivos sEMG contienen 8 columnas que indican la actividad muscular detectada por cada uno de los canales.

A continuación se muestra un resumen de los datos que se utilizaron para el análisis y la estructura de las carpetas con las cuales funciona el notebook adjunto en el repositorio

Fuente	Archivos	Tamaño	Contenido
Data	679 CSV	10.2 GB	sEMG de ocho canales señales crudas y normalizadas
Labels	679 CSV	179.2 KB	Segmentos sobre frames sEMG y rangos MVC
Labels 2	517 CSV	129.3 KB	Segmentos sobre frames MVNX
mvnx files	517 MVNX	56.7 GB	Movimiento Xsens de cuerpo completo
Subjs info	1 XLSX	9.4 KB	Demografía y antropometría
m files	2 MATLAB	9.0 KB	Filtrado y normalización sEMG

Tabla 2. Descripción de estructura de carpetas y descripción de contenido

Adicionalmente, la carpeta de `Labels/Subj_XX/` contiene las respectivas etiquetas de las acciones realizadas por los sujetos, con siete clases:

Código	Actividad	Código	Actividad
N	N-pose (De pie, reposo)	LT	Levantar desde la mesa
LF	Levantar desde el piso	W	Caminar/transportar el peso
K	Mantener el objeto levantado	PF	Colocar en el piso
PT	Colocar en la mesa		

Tabla 3. Clases de las etiquetas.

2. Valores faltantes y patrones de ausencia

La ausencia de datos se evaluó con tres criterios: archivos completos, valores dentro de la señal y muestras sin etiquetar.

2.1 Archivos faltantes

A partir del archivo experimental se construyó una lista esperada de ensayos (37 ensayos x 14 sujetos) y se comparó con los archivos encontrados en el dataset. Bajo este criterio, se detectó la falta del ensayo `Isokin_L_02kg_80bpm` del sujeto 12, ausente tanto en sEMG como en MVNX. Dado que el ensayo se encuentra ausente en ambos archivos, se trata de un archivo no registrado, no de un error de exportación. Los 679 archivos sEMG tienen su archivo de etiquetas correspondiente.

Sin embargo, se detecta que los sujetos 1 y 11 tienen un registro MVC por tarea y lado (6 archivos), el resto tiene un único registro ALL por lado (2 archivos).

2.2 Valores faltantes dentro de la señal

Después de realizar la lectura de todos los archivos, se determinó que ninguno de los 679 CSV de sEMG contaba con valores faltantes (NaN), ni huecos temporales. Además, dentro

del archivo de etiquetas no se detectan clases faltantes (Label sin NaN, ni fuera de los valores esperados por las 7 clases).

2.3 Patrón de ausencia: muestras sin etiquetar

Debido a que el proceso de etiquetado se realiza de manera manual, es esperado que no se cuente con el total de los datos etiquetados. Cerca de dos tercios de cada grabación está etiquetado, y la ausencia de etiquetado se concentra en el inicio y final de cada ensayo, posiblemente atribuible a los procesos de preparación y cierre de los ensayos.

Para el proceso de entrenamiento, se plantea el descarte de estas ventanas para el proceso de entrenamiento.

3. Estadísticas resumidas

3.1 Participantes

La cohorte está conformada por 14 sujetos, 12 hombres y 2 mujeres, con edades de entre 25 y 38 años, por lo que podemos decir que la muestra es pequeña y homogénea. A continuación se presentan las características antropométricas de los participantes:

Variable	Media	Desv. est	Mín	Mediana	Máx
Edad años	30.6	4.6	25.0	28.0	38.0
Masa corporal kg	71.6	7.8	58.0	72.0	90.0
Estatura cm	178.6	5.4	166.0	179.0	187.0
Longitud del pie cm	29.3	1.8	25.0	29.8	32.0
Altura del hombro cm	148.7	5.0	140.0	148.5	156.0
Ancho de hombros cm	41.6	3.9	32.0	42.0	46.0
Envergadura de codo cm	88.8	5.9	76.0	90.5	96.0
Envergadura de muñeca cm	133.8	13.2	103.0	140.5	148.0
Envergadura de brazo cm	176.6	8.6	161.0	177.5	188.0
Altura de cadera cm	101.3	3.8	96.0	100.9	108.0
Ancho de cadera cm	32.6	2.4	28.0	33.0	37.0
Altura de rodilla cm	52.7	2.8	46.0	52.2	59.0
Altura de tobillo cm	13.6	2.0	10.0	13.5	17.0
Grosor adicional de calzado	2.1	1.9	1.0	1.5	8.0

Tabla 4. Estadísticos antropométricos de los sujetos




Figura 1 Distribuciones univariantes de sexo edad masa corporal y estatura

Se obtuvo la correlación de Pearson entre las variables antropométricas. Las asociaciones deben considerarse descriptivas porque la muestra contiene sólo 14 sujetos. Una correlación alta puede reflejar escala corporal compartida y no evidencia una relación causal ni garantiza estabilidad fuera de la cohorte.




Figura 2 Matriz de correlación antropométrica

3.2 Registros sEMG

Los 679 archivos suman 27.7 millones de muestras, componiendo un total de 13.2 horas de registro. Un punto importante a destacar es que la frecuencia de muestreo entre los sujetos no es constante, sino que varía de entre 367 y 1006 Hz. Este punto resultará relevante en el proceso de entrenamiento, pues se requerirá de un remuestreo con una tasa común (la cantidad de registros por segundo) para no afectar el desempeño del modelo.

Métrica	Media	Desv.Est	Mínimo	Mediana	Máximo
Filas por archivo	40854.57	15403.00	9750	37800	103950
Duración s	69.86	16.69	9.70	72.41	113.90
Frecuencia Hz	585.29	156.61	366.66	529.06	1005.65
Frames MVNX	13775.3	3983.6	3085	14091	29222
Duración MVNX s	57.4	16.6	12.9	58.7	121.8
Tamaño MVNX MB	109.7	31.2	24.8	112.3	226.8

Tabla 5. Resumen y estadísticas de las series sEMG




Figura 3. Frecuencia de muestreo por sujeto

4. Valores faltantes y calidad temporal

El recorrido completo no encontró valores nulos, infinitos, timestamps no monótonos, huecos temporales ni canales constantes. La variación relativa máxima del periodo fue 1.01%, compatible con redondeo. No se requiere imputación numérica. La única ausencia estructural es una prueba completa del sujeto 12, que debe documentarse y excluirse de comparaciones que requieran un diseño balanceado.

5. Valores atípicos

5.1 Atípicos en la amplitud sEMG

En un archivo típico, el pico absoluto de la señal cruda es de ~15 mV (mediana) y el 90 % de los archivos queda por debajo de 34 mV. Sin embargo, el máximo llega a 1951.7 mV, por lo cual lo consideramos como un outlier o valor atípico. Para separar ruido aislado de un fallo de canal, se comparó la desviación estándar del canal más ruidoso contra la del canal típico de cada archivo (*Figura 4*).




Fig 3.1 Pico de amplitud por archivo




Fig 3.2 Desv. estándar máxima vs mediana por canal; la línea roja marca el umbral de 50 mV

Figura 4. Identificación de outliers

Los archivos con estos canales detectados como outliers son:

Archivo	Pico máximo mV	Std máxima mV	Sugerencia
Subj 07 MMH Bim R 08 kg Trial 3	1951.7	739.8	Excluir archivo
Subj 07 MMH Bim R 12 kg Trial 1	1581.7	487.7	Excluir archivo
Subj 07 MMH Bim R 12 kg Trial 2	1849.5	194.3	Excluir archivo
Archivos robustos adicionales	Hasta 150.7	Hasta 23.3	Inspección visual conservar si el artefacto es aislado

Tabla 6. Resumen de archivos con valores atípicos en algún canal

Este comportamiento es atribuible a algún electrodo o cable suelto, no a la actividad muscular. Estos datos anómalos serán excluidos del análisis para mantener la calidad de los datos en el proceso de entrenamiento.

5.2 Valores atípicos en las anotaciones

Los datos contenidos en la carpeta de `Labels/Subj_XX/` se conforman por columnas que indican el inicio y el final de la acción, así como la etiqueta de la acción que le corresponde, de acuerdo a las 7 clases presentadas anteriormente. Dada esta construcción, se esperaba que los archivos se mantuvieran ordenados y sin traslape, pero se encontraron 11 segmentos inconsistentes en dos archivos:

Archivo	Problema	Tratamiento
Subj 02 MMH One R 02 kg Trial 2	Segmentos solapados y un segmento invertido	excluir el ensayo
Subj 05 Isokin L 04 kg 80 bpm	Segmento final con longitud cero	Eliminar tras revisión

Tabla 7. Resumen de archivos con valores atípicos en las etiquetas

Dada la inconsistencia de estos datos, los archivos se excluyen de los análisis que dependen de las etiquetas, porque no es posible reconstruir la segmentación correcta sin revisión manual.

5.3 Valores por encima de 100% MVC

En teoría, `Norm_RMS` debería estar en 0–100 %MVC. En la práctica, 434 de 640 archivos de ensayo superan 100 % en el percentil 99 de algún canal (mediana del p99: 78.6 %, p90: 170 %). Como ocurre en la mayoría de los archivos, no se tratan como atípicos. Más bien reflejan que la ventana MVC (2–5 s) subestima la contracción máxima. Estos datos no se omitirán en la fase de entrenamiento, únicamente se considerará que el %MVC se interpreta como una escala relativa por sujeto y se aplica estandarización adicional antes del modelado.

6. Tendencias temporales

El conjunto es esencialmente una serie de tiempo, por lo que la dimensión temporal es central. Se identificaron cuatro tendencias.

6.1 Estructura temporal de cada ensayo

Las secuencias de etiquetas siguen un guion fijo. En MMH, 210 de 252 ensayos bimanuales y 158 de 168 ensayos a una mano siguen exactamente la secuencia

$N \rightarrow LF \rightarrow K \rightarrow PT \rightarrow N \rightarrow LT \rightarrow W \rightarrow PF \rightarrow N \rightarrow LF \rightarrow PT \rightarrow N \rightarrow LT \rightarrow W \rightarrow PF \rightarrow N \rightarrow LF \rightarrow PT \rightarrow N$

tres levantamientos del piso y dos de la mesa, con **K** solo en el primero. En los ensayos isocinéticos se repite $N \rightarrow LT \rightarrow PT$ cinco veces, y la variante estática es $N \rightarrow LT \rightarrow K \rightarrow PT \rightarrow N$.

6.2 Dinámica de la señal dentro del ensayo




Figura 5. Ejemplo de secuencia para un ensayo bimanual (sujeto 3, brazo izquierdo, 8 kg). Señal cruda del canal 1 (arriba) y envolvente Norm_RMS de los 8 canales (abajo).

La envolvente pasa de ~5–10 %MVC en reposo a 50–100 % al levantar el objeto, se mantiene alta durante K y W y cae en N. En los ensayos isocinéticos (Figura 6) cada repetición LT + PT aparece como una ráfaga periódica que sigue el ritmo del metrónomo.

Observemos que la variable de (%MVC) ya es una variable normalizada, ya viene aplicada en Norm_V y Norm_RMS. Reduce diferencias de escala y hace más comparables los canales y sujetos que, en voltaje crudo, difieren un orden de magnitud, por lo que la hace la candidata ideal para su uso en el entrenamiento del modelo.

6.3 Sincronización entre modalidades

Los relojes del sEMG y del sistema Xsens difieren en ~1 hora (mediana 3596.5 s, probablemente por zona horaria), más un residuo que varía entre ensayos (de -22s a +33 s). Además, el sEMG dura en promedio 12 s más. Por ello, las dos modalidades no se pueden alinear solo con las marcas de tiempo: se necesita una alineación por ensayo (p. ej. con un evento común como el primer levantamiento) antes de fusionarlas.




Figura 6. Desfase de reloj entre sEMG y MVNX (descontando 3600 s) y diferencia de duración por par de archivos

7. Desequilibrio de las acciones etiquetadas

La clase N (reposo) domina tanto en número de segmentos como en tiempo etiquetado, que es lo que verá un clasificador basado en ventanas:

Clase	Segmentos	Horas	Duración mediana (s)	% del tiempo
N	3520	3.74	3.66	43.1
LF	1196	0.84	2.43	9.7
K	475	0.73	4.40	8.5
PT	2075	1.29	2.21	14.8
LT	1692	0.79	1.65	9.1
W	813	0.67	2.97	7.7
PF	813	0.62	2.75	7.2

Tabla 8. Distribución de las categorías de las acciones




Figura 7. Variación de la frecuencia sEMG y distribución temporal de las clases

La categoría N ocupa el 43 % del tiempo, mientras que cada clase activa tiene entre 7 y 15 %, una razón de ~6:1 entre la clase mayoritaria y la minoritaria. La categoría K tiene pocos segmentos (475) porque aparece solo una vez por ensayo MMH, pero sus segmentos son los más largos. El desequilibrio es moderado y se debe tratar:

- Usar métricas robustas al desequilibrio: F1 macro y exactitud balanceada, además de la matriz de confusión.
- Ponderar la función de pérdida por la inversa de la frecuencia de clase, o submuestrear ventanas de N.

Ahora bien, con respecto a la relación entre los segmentos y los valores de Norm_RMS, se calculó el Norm_RMS medio de cada segmento (10,527 segmentos válidos). La relación con la clase es fuerte para separar reposo vs. actividad y débil entre clases activas:




Figura 8. Norm_RMS medio por clase y canal en MMH (izq.), distribución de la media por segmento por clase (cen.) y Norm_RMS medio por clase y carga (der) .

Las distribuciones de las clases activas se traslapan mucho, así que el sEMG por sí solo no basta para distinguirlas y conviene combinarlo con la captura de movimiento.

8. Preprocesamiento

Los controles de calidad anteriores muestran que el conjunto no requiere imputación numérica, pero sí una curación reproducible antes del modelado. El flujo propuesto busca conservar la trazabilidad por sujeto, prueba y modalidad, y evitar que decisiones de limpieza o particionado introduzcan sesgos o fuga de información.

8.1 Trazabilidad

No se detectaron valores nulos o infinitos, retrocesos en las marcas de tiempo, huecos temporales relevantes ni canales crudos constantes; por tanto, no se plantea imputar observaciones.

Antes de generar ventanas deben de excluirse los archivos de etiquetas Subj_02_MMH_One_R_02kg_Trial_2 y Subj_05_Isokin_L_04kg_80bpm, debido a solapamientos, un intervalo invertido y un segmento de longitud cero. Los intervalos fuera de las anotaciones se conservarán como desconocidos y no se reasignarán automáticamente a la clase neutral.

Los tres ensayos del sujeto 7 que superan el umbral físico de dispersión se retirarán temporalmente del conjunto de modelado.

8.2 Transformación y homogeneización de la señal

Para una primera línea base se utilizará Norm_RMS, ya normalizada respecto a la contracción voluntaria máxima. Si se reconstruyen características desde Raw_V, se reproducirá el procedimiento de los autores: filtro notch Butterworth de 49–51 Hz.

La frecuencia sEMG varía entre 366.66 y 1005.65 Hz, con una mediana de 529.06 Hz. En consecuencia, las ventanas se definirán en segundos y las señales se remuestrearán a una frecuencia común cuando el algoritmo requiera matrices de longitud fija. Para combinar sEMG con MVNX, que opera a 240 Hz, la alineación se realizará mediante las etiquetas nativas o eventos equivalentes de cada modalidad; no se realizará una unión directa por timestamp debido al desfase de los relojes.

8.3 Segmentación y selección de variables

La segmentación se limitará a intervalos con etiquetas válidas. Las ventanas tendrán duración y solapamiento expresados en segundos y no atravesarán transiciones de clase. Como variables de entrada podrán emplearse las series Norm_RMS o características temporales calculadas por canal, mientras que el identificador del archivo, el timestamp y el índice de frame se conservarán solo para trazabilidad. Sujeto, tarea, lado, carga y condición se mantendrán como metadatos para agrupación, estratificación y auditoría, no como predictores por defecto.

8.4 Particionado y control del desequilibrio

La separación entre entrenamiento, validación y prueba se realizará por sujeto mediante GroupKFold o una validación leave-one-subject-out. Esta decisión impide que ventanas altamente correlacionadas de una misma persona aparezcan en conjuntos distintos. Cualquier escalamiento robusto, selección de variables o ajuste de umbrales se estimará únicamente con los datos de entrenamiento y se aplicará después a validación y prueba.

El desequilibrio temporal se tratará dentro de cada partición de entrenamiento mediante ponderación de clases o submuestreo controlado de la clase neutral, sin alterar los conjuntos de evaluación. El desempeño se reportará con F1 macro, exactitud balanceada, métricas por clase y matriz de confusión. Además, se conservará una versión del conjunto previa a cada transformación para garantizar la reproducibilidad del proceso.

9. Conclusiones

9.1 Calidad

El conjunto de datos ofrece una base valiosa para desarrollar modelos de reconocimiento de actividad humana y estimación de carga. Integra señales de electromiografía de superficie con captura de movimiento corporal, etiquetas temporales y variables antropométricas de 14 participantes. La disponibilidad de 643 pruebas sEMG, aproximadamente 27.7 millones de muestras y 517 archivos MVNX permite estudiar tanto la activación muscular como la ejecución cinemática de las tareas. No obstante, el tamaño reducido de la cohorte limita la generalización de los resultados y obliga a evaluar cualquier modelo en sujetos no vistos.

La calidad interna de las series temporales es favorable. No se encontraron valores nulos, infinitos, retrocesos en las marcas temporales, huecos relevantes ni canales constantes. La variación máxima observada en el periodo de muestreo fue cercana al 1.01 %, compatible con efectos de redondeo. Esto indica que, dentro de cada archivo, la continuidad temporal es adecuada. Sin embargo, la frecuencia efectiva de muestreo sEMG cambia considerablemente entre sujetos y sesiones, desde aproximadamente 366.66 hasta 1005.65 Hz. Por ello, los registros no deben combinarse directamente por número de muestras sin aplicar remuestreo o construir ventanas con una duración expresada en segundos.

Las etiquetas representan uno de los principales puntos de control. Se identificaron 10,612 segmentos sEMG distribuidos en siete clases, pero dos archivos presentan inconsistencias: uno contiene segmentos solapados y un intervalo invertido, mientras que otro incluye un segmento final de longitud cero. Estos casos deben corregirse contra la fuente original o excluirse antes del entrenamiento. Asimismo, solo alrededor del 67 % de cada grabación se encuentra etiquetado. Los intervalos anteriores al primer segmento y posteriores al último no deberían asignarse automáticamente a la clase neutral, ya que podrían contener preparación, transiciones, reposicionamiento u otras conductas no documentadas. Es preferible tratarlos como datos desconocidos o excluirlos del entrenamiento supervisado.

9.2 Capacidad predictiva

La distribución temporal de las clases está desbalanceada. La clase neutral concentra aproximadamente el 43.05 % del tiempo etiquetado, mientras que cada clase activa representa entre 7.16 % y 14.81 %. En consecuencia, métricas globales como la exactitud pueden ofrecer una impresión excesivamente favorable si el modelo aprende principalmente a identificar la clase dominante. La evaluación debe incluir precisión, sensibilidad y F1 por clase, además de promedios macro y matrices de confusión.

El análisis de amplitud muestra que la señal sEMG permite diferenciar con claridad el reposo de la actividad. Sin embargo, las distribuciones de las diferentes actividades activas presentan solapamientos importantes. Esto indica que la amplitud muscular, utilizada de forma aislada, probablemente no sea suficiente para distinguir con precisión todas las clases. Para mejorar la clasificación será necesario incorporar características temporales, información conjunta de varios canales y, posteriormente, variables cinemáticas derivadas de MVNX.

9.3 Limitaciones

La relación entre carga y activación muscular es uno de los hallazgos más consistentes. En las pruebas MMH bimanuales, la media de Norm RMS aumenta de forma monótonica al pasar de 2 a 8 y 12 kg en todas las clases activas. En la clase K, por ejemplo, el nivel medio aumenta aproximadamente de 22.0 a 75.1 %MVC, mientras que en W pasa de 22.3 a 72.8 %MVC. Este patrón respalda el uso de sEMG para estimar niveles de carga. No obstante, la relación debe validarse separando participantes, porque las diferencias individuales de fuerza, técnica de ejecución y calidad de la contracción MVC pueden explicar una parte relevante de la variación.

La normalización respecto a MVC requiere una revisión específica. En 434 de 640 pruebas válidas, al menos un canal supera 100% MVC en el percentil 99, y se observan máximos considerablemente superiores. Superar ese valor no representa necesariamente un error: puede significar que la contracción de referencia fue submáxima o que la tarea produjo una activación mayor. Aun así, la alta frecuencia de estos casos sugiere que la normalización no puede asumirse como una escala perfectamente comparable entre sujetos y canales. Es recomendable complementar Norm RMS con escalado robusto y análisis por participante.

El análisis antropométrico muestra asociaciones esperables entre masa corporal, estatura y distintas medidas corporales. Sin embargo, estas correlaciones son descriptivas y deben interpretarse con cautela debido a que solo se cuenta con 14 participantes. No pueden considerarse evidencia de causalidad ni utilizarse como fundamento para conclusiones poblacionales. Además, la cohorte está formada por 12 hombres y 2 mujeres, lo cual limita

el análisis de diferencias por sexo y puede introducir sesgos si los modelos se aplican a poblaciones más diversas.

9.4 Recomendaciones de modelado

La fusión entre sEMG y MVNX no debe realizarse mediante una unión directa por timestamp. Los relojes presentan un desfase cercano a una hora y existe variación residual entre pruebas. Además, cada modalidad utiliza una base de frames diferente. La coincidencia de las etiquetas permite relacionar semánticamente los registros, pero no garantiza su sincronización física. La integración multimodal debe apoyarse en las etiquetas nativas de cada modalidad y en eventos observables compartidos, como inicios de movimiento, máximos de velocidad o cambios de postura.

Para el modelado se recomienda comenzar con una línea base basada en Norm RMS, ventanas temporales definidas en segundos y una frecuencia común de muestreo. La división de entrenamiento, validación y prueba debe realizarse por sujeto mediante GroupKFold o leave-one-subject-out. Una partición aleatoria por filas o ventanas provocaría fuga de información, porque registros del mismo participante podrían aparecer simultáneamente en entrenamiento y prueba.

En conjunto, el dataset es adecuado para continuar hacia una fase de modelado, siempre que antes se establezca un proceso de curación reproducible. Este proceso debe documentar la prueba faltante, resolver las etiquetas inconsistentes, definir el tratamiento de los tres archivos atípicos, armonizar la frecuencia sEMG y preservar los intervalos no etiquetados como desconocidos. La primera meta realista consiste en diferenciar reposo de actividad. La clasificación detallada de actividades y la fusión multimodal constituyen objetivos viables, pero requerirán características temporales, información de movimiento y validación estricta en participantes no observados.

Pregunta	Conclusión	Evidencia
El dataset está completo	Casi completo	Falta una prueba del sujeto 12 en sEMG y MVNX
La calidad temporal es adecuada	Sí dentro de cada archivo	No hay nulos infinitos retrocesos ni huecos
La frecuencia es uniforme	No	Varía de 366.66 a 1005.65 Hz
La sEMG diferencia actividades	Distingue reposo de actividad	Las clases activas muestran solapamiento
La sEMG informa sobre la carga	Sí de forma descriptiva	K y W aumentan cerca de tres veces entre 2 y 12 kg
Las modalidades están listas para fusionarse	No sin alineación adicional	Existe desfase de reloj y bases de frames distintas
Puede usarse una partición aleatoria	No	La cohorte es pequeña y existe efecto sujeto

Tabla 9. Resumen de las conclusiones obtenidas durante el EDA

10. Referencias

- Bassani, G., Filippeschi, A., & Avizzano, C. A. (2021). A dataset of human motion and muscular activities in manual material handling tasks for biomechanical and ergonomic analyses. IEEE Sensors Journal, 21(21). <https://ieeexplore.ieee.org/document/9539228>
- Conjunto de datos: <https://zenodo.org/records/4633087>